

FASE 1 - Fundamentos de Inteligência Artificial -

Aula 1 - Introdução e História

Iniciando em 31-08-2025

URL da página da aula na plataforma

<https://on.fiap.com.br/mod/conteudoshtml/view.php?id=520835&c=14006&sesskey=meEfJGTFs1>

URL do PDF da aula

<https://on.fiap.com.br/mod/conteudospdf/view.php?c=14006&id=520839>

Algumas conclusões sobre o uso combinado de técnicas de aprendizado não supervisionado e com técnicas de aprendizado supervisionado.

Análise de Cenário - questionamento feito a Gemini

É correto concluir que dentro de um universo de dados a sequencia lógica de tratamento de dados e aprendizagem de máquina Machine Learning ML, a sequencia abaixo é coerente?

1 - primeiro utilizar técnicas de aprendizado não supervisionado para extração de agrupamentos através de técnicas de clustering;

2 - tratar separadamente os agrupamentos e aplicar aprendizado de máquina supervisionado para definir um % probabilidade de enquadramento em classificações já predefinidas.

Resposta do Gemini - concordando com a minha análise e aferindo meu correto entendimento e aprendizado sobre o assunto

Sua conclusão é uma abordagem muito interessante e, em muitos casos, **é uma sequência de etapas coerente e eficaz** para lidar com conjuntos de dados complexos em Machine Learning. Essa estratégia é conhecida como uma forma de **aprendizagem semi-supervisionada** ou **pré-processamento com clustering**.

Vamos analisar a lógica de cada passo:

1. Pré-processamento com Aprendizagem Não Supervisionada (Clustering)

É perfeitamente lógico começar com o aprendizado não supervisionado, como o **K-means** ou outros algoritmos de clustering.

- **Por quê?** Os dados brutos podem ser muito grandes, heterogêneos e desestruturados. Ao agrupar os dados em clusters, você está, na verdade, descobrindo a **estrutura natural** e os padrões subjacentes neles. Isso pode revelar que seu universo de dados não é homogêneo, mas sim composto por subgrupos distintos.
- **Benefícios:** Essa etapa ajuda a reduzir a complexidade e pode melhorar a qualidade das previsões futuras. Por exemplo, em um conjunto de dados de clientes, o clustering pode identificar diferentes "segmentos de clientes" (ex: clientes que comprem muito, clientes que comprem pouco, clientes que se interessam por promoções, etc.).

2. Classificação Supervisionada em Agrupamentos Separados

Após o clustering, a sua ideia de tratar cada agrupamento separadamente com um modelo de aprendizado supervisionado faz total sentido.

- **Por quê?** Um modelo de classificação supervisionada (como a **Regressão Logística** ou o **SVM**) aprende a partir de dados rotulados. Se você treinar um único modelo para todo o conjunto de dados, ele pode ter dificuldade em capturar as nuances e os padrões específicos de cada subgrupo. Ao treinar um modelo para cada cluster, você está adaptando o algoritmo de classificação às características únicas de cada grupo.
- **Benefícios:** Essa abordagem segmentada leva a modelos mais especializados e, conseqüentemente, mais precisos. Um modelo treinado para prever a probabilidade de compra de "clientes que se interessam por promoções" será, provavelmente, mais preciso do que um modelo genérico que tenta prever o comportamento de todos os clientes de uma vez.

Resumo e Considerações Adicionais

Em suma, a sequência que você descreveu é uma estratégia de **"dividir para conquistar"** que pode ser muito poderosa. Em vez de usar um modelo único para um problema complexo, você o divide em problemas menores e mais gerenciáveis, o que pode resultar em um desempenho geral superior.

Essa abordagem não é a única, mas é definitivamente uma sequência lógica e bem-aceita em muitas áreas da ciência de dados. A validade da sua conclusão dependerá, em última análise, dos dados específicos e do problema que você está tentando resolver.