

FASE 1 - Machine Learning - Aula 4 - Feature Scaling

<https://on.fiap.com.br/mod/conteudoshtml/view.php?id=520860&sesskey=1Pplji7Wb1>

- **Feature Scaling** é a categoria geral de técnicas usadas para mudar a escala dos valores das features (variáveis) para que fiquem em um intervalo ou distribuição comparável.
- Feature Scaling em português pode ter vários nomes com abordagens e significados diferentes
 - Normalização
 - Escalonamento
 - Padronização
- Nomes em inglês dos sub-tipos de Feature Scaling
 - Standardization (Z-score Normalization)
 - Padronização
 - O z-score é aplicado para cada ponto de dado nulo calculando a média e o desvio padrão para saber o qual longe esse valor está da média. Ele utiliza o cálculo da Variância diretamente para a sua transformação.
 - Sua principal função é resolver problemas de diferenças de escala e a sensibilidade dos algoritmos a essas diferenças;
 - Quando o z-score é aplicado em todas as features (variáveis) ele cria uma escala comum, removendo viés que o tamanho da unidade de medida pode causar;
 - Exemplos de escalas muito amplas onde o z-score atua
 - Idade: variando de 20 a 70
 - Salário: variando de 50.000 a 500.000
 - z-score atua transformando ambas as features para que tenham
 - Média = 0
 - Desvio-Padrão = 1
 - Desta forma, o modelo trata a variação (o “peso”) na idade e no salário como igualmente importantes, já que ambas agora variam entorno de 0 com uma dispersão 1.
 - Recomendado para os seguintes modelos de ML
 - Algoritmos de Otimização Baseados em Gradientes
 - Regressão Logística;
 - Redes Neurais;
 - Algoritmos Baseados em Distância
 - K-Nearest Neighbors
 - KNN e K-Means
 - Análise de Componentes Principais (PCA)

- Normalization (Min-Max Scaling)
 - Normalização / Escalonamento
 - Min-Max Scaling
 - Transforma os dados para que fique em um intervalo fixo, geralmente [0,1]
- Outros
 - Robust Scaling
 - Unit Vector Normalization
 - Max Abs Scaling
 - Logarithmic Scaling
 - Power Transformer
 - Quantile Transformer

Abaixo uma verdadeira aula sobre aplicação de dois tipos de Feature Scaling:

- Padronização (standardization)
 - z-index
- Normalização ou escalonamento (Normalization)
 - Min-Max scaling

09-10-2025

Seguir com o material da plataforma sobre Feature Scaling

<https://on.fiap.com.br/mod/conteudoshtml/view.php?id=520860&sesskey=1Pplji7Wb1>

Assistindo o vídeo da aula

Transformação “Label Encoders”

O tratamento categórico nos dados de texto, os rótulos podem ser transformados para números inteiros, processo chamado “Label Encoders”

Exemplo de features que podem ser transformados em inteiros com a transformação “Label Encoders”

- Surname
 - Boni
 - Mitchell
- Geography
 - France
 - Spain
- Gender
 - Female
 - Male

A diferença do “Label Encoder” para o “One-Hot-Encoder” é que o LE não aumenta o tamanho da base de dados, já o OHE aumenta a quantidade de colunas.

Quais são os modelos de ML onde se recomenda o uso de "One-Hot Encoding" e onde "Label Encoding" é mais indicado?

É uma excelente pergunta! A escolha entre **One-Hot Encoding** e **Label Encoding** depende fundamentalmente do tipo de modelo de Machine Learning que você está utilizando e da natureza da sua variável categórica.

One-Hot Encoding (OHE)

Onde se recomenda:

O **One-Hot Encoding** é recomendado para variáveis categóricas **nominais** (onde não há ordem ou hierarquia entre as categorias) e, crucialmente, para **modelos que calculam distância ou assumem relações lineares** entre as *features*.

Tipo de Variável	Modelo de ML	Razão
Nominal (e.g., cor: azul, verde, vermelho)	Regressão Linear/Logística	Evita que o modelo assuma erroneamente que o "azul" (codificado como 1) é "menor" ou mais próximo do "verde" (codificado como 2) do que do "vermelho" (codificado como 3). O OHE cria colunas binárias (0 ou 1) que tratam cada categoria como um <i>feature</i> independente.
Nominal	Máquinas de Vetores de Suporte (SVM)	São baseadas em distâncias no espaço de <i>features</i> . Um Label Encoding criaria distâncias incorretas entre categorias.
Nominal	K-Nearest Neighbors (KNN)	Baseado em distância. O OHE garante que a distância entre categorias não seja artificialmente distorcida por um valor numérico.

Nominal	Redes Neurais	Embora haja exceções, OHE é frequentemente a escolha mais segura para categorias nominais para evitar que a rede atribua um significado ordinal a valores numéricos.
----------------	----------------------	--

Em resumo: Use **OHE** sempre que a ordem das categorias não tiver significado lógico, especialmente com modelos baseados em **distância ou magnitude**.

Label Encoding (LE)

Onde é mais indicado:

O **Label Encoding** é mais indicado quando a variável categórica é **ordinal** (ou seja, há uma ordem ou hierarquia clara entre as categorias) ou quando se utiliza **modelos baseados em árvores**.

Tipo de Variável	Modelo de ML	Razão
Ordinal (e.g., nível de escolaridade: básico, médio, superior)	Qualquer modelo	O LE (ex: básico=1, médio=2, superior=3) preserva a ordem inerente aos dados. O modelo se beneficia dessa relação sequencial.
Nominal ou Ordinal	Árvores de Decisão, Random Forest, Gradient Boosting (XGBoost, LightGBM, CatBoost)	Modelos baseados em árvores são insensíveis à magnitude dos valores (eles apenas procuram um ponto de corte para dividir os dados). O LE é preferido porque: 1) Preserva a ordem se for ordinal; 2) Reduz drasticamente o número de <i>features</i> (não cria dezenas de colunas, como o OHE), o que acelera o treinamento e reduz a complexidade do modelo.

Em resumo: Use **LE** para variáveis **ordinais** ou, por questões de performance e simplicidade, em **modelos de árvore**, pois eles não sofrem com a suposição de ordenação incorreta da mesma forma que os modelos lineares.

Dicas de Prática

1. **Alta Cardinalidade:** Se uma variável nominal tem muitas categorias (alta cardinalidade, e.g., 50 países), o **One-Hot Encoding** criará muitas colunas, levando ao problema de "**maldição da dimensionalidade**" e *sparse data*. Nesses casos, considere métodos como *Target Encoding* ou agrupe as categorias menos frequentes.
2. **CatBoost:** Um algoritmo de *boosting* notável é o **CatBoost**, que possui um método interno e avançado de *encoding* categórico, muitas vezes eliminando a necessidade de *encoding* manual (LE ou OHE).

Material complementar da aula

https://github.com/FIAP/CURSO_IA_ML