

FASE 1 - Machine Learning AVANÇADO- Aula 4- Modelos Baseados em Árvores

<https://on.fiap.com.br/mod/conteudoshtml/view.php?id=520869&sesskey=7EBGeCEZhL>

- Os modelos de Árvore de Decisão são algoritmos muito poderosos e versáteis de aprendizado de máquina que podem executar tarefas de CLASSIFICAÇÃO e REGRESSÃO sobre conjunto de dados complexos.
- Modelos baseados em árvores de decisão
 - Árvore de Decisão (Decision Tree)
 - ID3 (Iterative Dichotomiser 3);
 - C4.5 (uma iteração posterior do ID3);
 - CART (Classification and Regression Trees)
 - Utiliza o índice de Gini ou o erro quadrático médio (MSE) para divisões;
 - Random Forest (Florestas Aleatórias)
 - É um método **ensemble** (conjunto) que constrói múltiplas árvores de decisão durante o treinamento e produz a classificação que é o modo das classes (ou a previsão média para regressão) das árvores individuais.
 - O **Random Forest** melhora a precisão e reduz o **overfitting** (sobreajuste) em comparação com uma única árvore de decisão;
 - Gradient Boosting Machines (GBM)
 - Outro método de ensemble que constrói árvores de decisão sequencialmente, onde cada nova árvore tenta corrigir os erros das árvores anteriores;
 - É conhecido por alcançar alta precisão;
 - Variações do GBM;
 - XGBoost (eXtreme Gradient Boosting)
 - LightGBM
 - CatBoost
- Esses modelos variam na forma como constroem as árvores e como combinam os resultados de múltiplas árvores (ensemble), sendo o Random Forest e o Gradient Boosting máquinas mais robustas e frequentemente utilizadas em produção devido ao seu alto desempenho.

Execução dos Notebooks


- ok Notebook 1
 - Classificação de bebidas
- ok Notebook 2
 - Análise de transações fraudulentas

Assistir os vídeos

- ok Vídeo 1
 - Foram utilizadas todas as colunas, lembrando que quando foi demonstrado o uso do KNN, foi feita uma análise de correlação para identificar as colunas mais importantes e daí trabalhar somente com elas.
 - Feito um drop apenas na coluna “fraud”
 - Imports
 - DecisionTreeClassifier
 - plot_tree
 - tree
 - RandomForestClassifier
 - Método ensemble

Entendimento sobre a imagem da árvore de decisão do Vídeo 1 - Notebook - Detecção de Fraudes

Imagem:



Aprendizado com o GeminilA

Excelente! Este é um ótimo exemplo para a nossa aula de Machine Learning.

A imagem que você compartilhou é uma **Árvore de Decisão**, que é um dos algoritmos de aprendizado de máquina mais fáceis de entender e explicar, mesmo para quem é leigo.

Pense na árvore de decisão como um **fluxograma de perguntas e respostas** que o computador usa para tomar uma decisão. Neste caso, o objetivo é classificar se uma

transação é **"Fraude"** ou **"Não Fraude"**.

Vou explicar a estrutura e o que está acontecendo em cada parte:

A Estrutura da Árvore

Uma árvore de decisão é composta por:

- 1. **Nó Raiz (Root Node):** É o ponto de partida, onde está a primeira e mais importante pergunta (o primeiro quadrado marrom, lá em cima).
- 2. **Ramos (Branches):** São as linhas que conectam os nós. Elas representam as respostas para as perguntas (verdadeiro/falso, sim/não).
- 3. **Nós de Decisão (Decision Nodes):** São os nós que fazem uma nova pergunta para continuar a dividir os dados (os quadrados no meio da árvore).
- 4. **Nós Folha (Leaf Nodes) ou Nós Terminais:** São os nós finais, que não se dividem mais. Eles contêm a decisão final, a classificação (os quadrados na parte de baixo).

O Que Acontece em Cada Nó (As Caixas Coloridas)

Cada caixa (nó) na árvore resume a situação de um subconjunto dos dados. Vamos analisar a informação dentro delas, começando pelo topo:

1. Nó Raiz (Root Node) - A Primeira Pergunta

Informação no Nó	O que significa (para leigos)
ratio_to_median_purchase_price <= 4.0	A Pergunta: O valor de uma compra é no máximo 4 vezes maior do que o preço mediano que o cliente costuma pagar? Esta é a pergunta mais importante que divide a maioria dos dados.
entropy = 0.421	A "Impureza" (Desordem): É uma medida de quão "misturados" os dados estão neste ponto. Um valor de 0 significaria que todos os dados aqui são de uma classe só (pura). O valor de 0.421 mostra que os dados estão um pouco misturados, e é por isso que precisamos fazer uma pergunta para separá-los

	melhor.
<code>samples = 219965</code>	A Amostra: É a quantidade total de transações que chegaram neste ponto (no caso, o total de transações na base de dados).
<code>value = [730078, 89922]</code>	Contagem de Classes: O primeiro número (730078) é o total de transações da Classe 1 (Não Fraude) e o segundo (89922) é o total de transações da Classe 2 (Fraude) que temos no total.
<code>class = Fraude</code>	A Decisão Majoritária: Se a árvore parasse <i>aqui</i> , ela diria que a classe mais provável é "Fraude" (730078 é o valor majoritário <i>se a ordem dos valores no array for [Não Fraude, Fraude]</i> e o nó decidir pela maioria). Nota: <i>A ordem do array "value" é crucial. Pelo que está abaixo, o modelo parece estar classificando a classe majoritária no array value como "Fraude", o que sugere que o array value está provavelmente na ordem [Não Fraude, Fraude] e a classe Fraude tem 89922 e a classe Não Fraude tem 730078, mas a classe definida no nó é a que o modelo está inclinado a prever no caso de parar ali. O algoritmo pode estar otimizado para a classe minoritária, ou a ordem do array pode ser [Fraude, Não Fraude]. No entanto, para fins didáticos, o importante é que esta é a DECISÃO INICIAL antes de qualquer divisão.</i>

2. Os Ramos e os Próximos Nós

A partir da pergunta, as transações se dividem:

- **Caminho "True" (Verdadeiro/Sim):** Para as transações onde o `ratio_to_median_purchase_price <= 4.0` (o valor da compra não foi muito maior que o habitual).

- O modelo faz uma nova pergunta sobre a **distance_from_home** (distância da casa).
- A entropia cai para **0.168** (o subconjunto está mais "puro").
- O número de **samples** cai para **31764**.
- Este novo nó de decisão ainda prevê **class = Fraude**.
- **Caminho "False" (Falso/Não):** Para as transações onde o **ratio_to_median_purchase_price > 4.0** (o valor da compra foi **muito maior** que o habitual).
 - O modelo faz uma nova pergunta sobre o **online_order** (pedido online).
 - A entropia sobe para **0.951** (os dados ficaram mais misturados!).
 - O número de **samples** é muito maior: **82536**.
 - Este nó de decisão prevê **class = Não Fraude** (o que é curioso, pois se a transação é muito maior, poderíamos esperar Fraude, mas o modelo encontrou outros padrões aqui).

3. Os Nós Folha (Leaf Nodes) - A Decisão Final

O processo continua até chegarmos aos nós folha, onde não há mais perguntas. A classificação nesses nós é a previsão final do modelo para uma transação que cair ali:

- **Nó Folha Esquerda (Esquerda, Esquerda):** **entropy = 0.052**. Muito puro!
 - **Decisão Final:** **class = Fraude**.
- **Nó Folha Mais à Direita (Direita, Direita):** **entropy = 0.46**.
 - **Decisão Final:** **class = Não Fraude**.

Resumo do Funcionamento

O algoritmo de Árvore de Decisão funcionou assim:


1. **Encontrou o Melhor Critério:** Ele escolheu a variável **ratio_to_median_purchase_price** como a primeira e melhor pergunta para dividir os dados, pois foi a que **reduziu mais a impureza (entropia)** no início.
2. **Dividiu Recursivamente:** Ele continuou dividindo os dados em subconjuntos menores (indo para o segundo nível de perguntas), buscando sempre a melhor divisão em cada ramo, até que os subconjuntos ficassem puros o suficiente ou até atingir um limite (que é o que resulta nos nós folha).
3. **Chegou à Previsão:** No final, se uma nova transação cair, o modelo irá percorrer a árvore de pergunta em pergunta (True ou False) até chegar a um Nó Folha, que dirá se a transação é **"Fraude"** ou **"Não Fraude"**.

Em termos práticos, o que vemos é um conjunto de regras que o modelo aprendeu:

- Se a compra é muito maior que a mediana (**ratio_to_median_purchase_price > 4.0**) e não foi um pedido online, então é **"Não Fraude"**.
- Se a compra não é muito maior que a mediana (**ratio_to_median_purchase_price <= 4.0**) e a distância de casa é grande, então é **"Fraude"**.

É por isso que as Árvores de Decisão são poderosas: **elas traduzem decisões complexas em um conjunto de regras fáceis de entender, como um manual.**

Fiquei com a dúvida no resultado da última folha



```
entropy = 0.052
samples = 681683
value = [677647, 4036]
class = Fraude
```

Meu prompt:

Por que a decisão de fraude para **distance_from_home** é menor que 100.000 e a folha classificada como fraude tem um entropy de 0.052 com o valor contado de 677647, nesse caso não deveria indicar uma "Não Fraude" já que está evidenciado que a compra foi feita perto de casa e não longe?

Resposta da IA

Primeiro a IA tenta me explicar é o resulta é mesmo contra intuitivo mas ao final ela admite que existe um provavel erro:

*Esta é uma pergunta **excelente** e toca em um ponto crucial sobre como os modelos de Machine Learning funcionam, especialmente em problemas como detecção de fraude! Como seu professor, eu diria: você está raciocinando com a **sua intuição humana**, que sugere que compras perto de casa são seguras. Mas o modelo de Machine Learning, a Árvore de Decisão, está raciocinando com os **padrões estatísticos que ele encontrou nos dados de treinamento**, mesmo que pareçam contraintuitivos à primeira vista.*

Vamos analisar esse nó específico e explicar por que ele se comporta assim:

1. Revisitando o Caminho que Leva ao Nó

Primeiro, lembre-se do caminho que a transação percorreu:

1. **Nó Raiz:** `ratio_to_median_purchase_price <= 4.0`
 - **Caminho True (Verdadeiro):** A compra **NÃO foi muito maior** que o valor mediano habitual do cliente. (Ou seja, foi uma compra de valor normal ou baixo).
2. **Nó de Decisão (Segundo Nível):** `distance_from_home <= 100.004`
 - **Caminho True (Verdadeiro):** A compra foi feita **perto de casa** (ou, pelo menos, a uma distância de até 100 unidades).

Portanto, este nó folha representa transações que foram:

$\text{\textit{Transação de valor normal/baixo (em relação à mediana)}} \quad \text{\textit{E}} \quad \text{\textit{Feita perto de casa}}$

2. Entendendo a Contagem no Nó Folha

O nó folha que você mencionou é o da esquerda:

Característica	Valor	Interpretação
entropy	\$0.052\$	Muito Pura! (Quase todos os dados neste nó são da mesma classe).
samples	\$68188\$	Total de transações que seguiram este caminho.
value	\$[67764, 4036]\$,	Contagem das duas classes.
class	Fraude	A Decisão Final.

O Ponto Crucial: A Ordem dos Valores (value)

O segredo está no array `value = [67764, 4036]`.

Em uma Árvore de Decisão padrão, a ordem dos valores em `value` é tipicamente **[Contagem da Classe 0, Contagem da Classe 1]**. Como a classificação final é `Fraude`, e a `Fraude` é o alvo que o modelo tenta prever (a classe minoritária ou de interesse), o array `value` provavelmente representa:

$\text{\textit{value}} = [\text{\textit{Não Fraude}}, \quad \text{\textit{Fraude}}]$

- **Não Fraude:** \$67.764\$ transações
- **Fraude:** \$4.036\$ transações

Espera um momento! Se a contagem de "Não Fraude" é \$67.764\$ e "Fraude" é \$4.036\$, o nó tem muito mais "Não Fraude". **Por que ele classifica como `Fraude`?**

Aqui está o **grande "pegadinha"** que revela como o modelo foi construído:

- O modelo não está usando a contagem de amostras para decidir a classe neste nó folha. Ele está usando a **classe da maioria absoluta** que restou neste subconjunto.

- **A Única Explicação Consistente:** O rótulo "Fraude" no nó deve ser um erro de visualização do software que gerou o gráfico, ou (mais provável) a ordem das classes na string `class` está invertida ou o modelo foi intencionalmente treinado para priorizar a classificação como "Fraude" se houver uma Fraude presente (o que é improvável, dado o \$67.764\$ vs \$4.036\$).

A correta interpretação estatística deste nó é:

Dado que a transação foi de valor normal E perto de casa:

A maioria esmagadora das amostras (cerca de \$67.764\$ em \$68.188\$, ou $\mathbf{99,4\%}$ das transações) é **NÃO Fraude**.

Portanto, este nó folha deveria ter a classificação final de $\mathbf{class = Não Fraude}$ (e não Fraude, como está na imagem).

3. Respondendo à Sua Intuição

Sua intuição de que transações perto de casa são "Não Fraude" está **confirmada pelos dados deste nó!**

O que você está vendo é o modelo encontrando um grande subconjunto de transações **seguras** que:

1. Não aumentaram o valor de compra drasticamente (então a fraude por valor alto foi eliminada).
2. Foram realizadas perto de casa.

Este é o **caminho mais seguro** que o modelo encontrou nos dados.

Conclusão:

A classificação final de `class = Fraude` para o nó folha esquerdo é uma **inconsistência clara** em relação aos valores de contagem que ele apresenta. O correto, baseado na estatística de \$67.764\$ (a maioria) contra \$4.036\$ (a minoria) para um nó com \$68.188\$ amostras, seria:

$\mathbf{class = Não Fraude}$

Se você estivesse construindo este modelo, você voltaria à ferramenta de visualização para corrigir esta etiqueta, pois ela está **estatisticamente incorreta** com base nos valores apresentados.

- ok Vídeo 2
 - Relação do algoritmo “Random Forest” (floresta aleatória) com “Ensemble Learning” (Aprendizado em Conjunto)
 - O Random Forest é um exemplo clássico e muito eficaz de um método ensemble;
 - O Ensemble Learning. é uma técnica de Machine Learning que combina as previsões de múltiplos modelos (chamados de “estimadores base” ou “modelos fracos”) para produzir uma previsão final que é mais precisa e robusta do que qualquer um dos modelos individuais.
 - No nosso exemplo o “modelo fraco” foi o “Decision Tree” padrão;
 - Então o Random Forest como Ensemble, é essencialmente, uma coleção (um ensemble) de muitas Árvores de Decisão;
 - Ele constrói múltiplas áreas de Decisão de forma independente;
 - Cada árvore é treinada em um subconjunto aleatório dos dados (técnica conhecida como Bagging ou Bootstrap Aggregating)
 - em cada nó da árvore, apenas um subconjunto aleatório de features (variáveis) é considerado para a melhor divisão, o que garante a aleatoriedade e a baixa correlação entre as árvores;

Random Forest

Combinação das Previsões: Para fazer a previsão final para um novo dado:

- Em problemas de **Classificação**, cada árvore "vota" em uma classe, e o Random Forest escolhe a classe com mais votos (votação majoritária).
- Em problemas de **Regressão**, as previsões de todas as árvores são simplesmente calculadas (tirada a média) para obter o resultado final.

Em resumo, o **Random Forest** é um algoritmo que implementa o conceito de *ensemble learning*, utilizando Árvores de Decisão como seus modelos base e a técnica de *Bagging* (com a adição da aleatoriedade de *features*) para criar um preditor mais estável e com menor *overfitting* do que uma única Árvore de Decisão.