

FASE 1 - Machine Learning AVANÇADO - Aula 5- Validação Cruzada e Pipeline no Sklearn

<https://on.fiap.com.br/mod/conteudoshtml/view.php?id=520870&sesskey=D57fbkLQ9e>

Anotações

- Validação cruzada “Cross-Validation” em qualquer algoritmo de Machine Learning, incluindo o K-Nearest Neighbors (KNN). é obter uma estimativa mais robusta e confiável do desempenho e da **capacidade de generalização do modelo em dados não vistos**.
- Videos
 - ok Video 1 - algoritmo de classificação
 - Base de dados de classificação de problemas ortopedicos
 - Classes
 - Sem problemas (Noraml - NO);
 - Hérnia de Disco (Disk Hernia - DH);
 - Espondilolistese (Spondylolisthesis - SL);
 - Utilizado o KNN com parametrizado psara 3 vizinhos
 - Técnica para descobrimento dos hiperparâmetros do algoritmo de forma mais rápida sem precisar testar um por um;
 - Os “kFold” é a variável resultante do processo de Validação Cruzada.
 - Já o cross_val_score, serve para fazer a validação de dados.
 - Modelo pacificador é qual algoritmo de classificação foi usado previamente, no caso do exemplo o KNN
 - A validação cruzada serve para testar vários algoritmos;
 - **GridSearchCV** é o método de seleção dos melhores Ks em uma algoritmo de KNN
 - É considerado método de “força bruta” para otimização de hiperparâmetros
 - Objetivo é automatizar e sistematizar o processo de otimização de hiperparâmetros para modelos de machine learning.
 - O ajuste de hiperparâmetros é importante para evitar o “overfitting” e o “underfitting”
 - No KNN a definição do número de vizinhos, o K ou n_neighbors, é um exemplo de hiperparâmetro
 - No KNN o GridSeachVB aumenta a produtividade, principalmente eliminando o trabalho manual e garantindo a seleção dos hiperparâmetros ideais de forma sistemática;
 - Automação da otimização de Hiperparâmetros
 - Substitui o teste de Erro Manual;

- Sem o GridSearchCV o cientista de dados precisaria testar várias combinações de hiperparâmetros (como diferentes valores de K, métricas de distâncias e pesos), manualmente, treinando e avaliando o modelo a cada tentativa. O GridSearchCV automatiza esse processo, testando exaustivamente todas as combinações que você pode especificar.
 - Ajuda a encontrar “Melhor Modelo” com confiança
 - Ele retorna automaticamente a combinação de hiperparâmetros que obteve a melhor performance (maior acurácia, F1-Score e etc)
 - Uso eficiente de recursos de computação
 - Paralelização (n_jobs)
 - Configuração de uso da quantidade de núcleos da CPU
 - Ganho de tempo total
- param_grid
 - É a parametrização do GridSearchCV
 - É um dicionário de hiperparâmetros;
- Alguns métodos de validação considerados no exemplo
 - make_scorer
 - accuracy_score
 - f1_score

- ok Notebook -
 - https://github.com/FIAP/Pos_Tech_DTAT/blob/4adb2f888cacb37fa813674e3ec2e970c63d3c20/Aula%2005/Notebooks/Valida%C3%A7%C3%A3o%20Cruzada.ipynb
 -
- Material complementar
 - OpenML Vertebra-column
 - <https://www.openml.org/search?type=data&sort=runs&id=1523&status=active>
 -