

FASE 1 - Machine Learning AVANÇADO- Aula 9 - Classification Report e Métricas de Classificação

<https://on.fiap.com.br/mod/conteudoshtml/view.php?id=520871&sesskey=tdGHshNCLk>

Anotações

Video 1


Matriz de confusão "confusion_matrix"

A matriz de confusão (*confusion matrix*) é uma tabela utilizada em *Machine Learning*, especialmente em problemas de **classificação**, para **avaliar o desempenho de um modelo**.

Ela permite visualizar e resumir a performance do algoritmo comparando as classes **reais** (os valores verdadeiros dos dados) com as classes **previstas** pelo modelo.

Para um problema de classificação binária (duas classes, por exemplo, "Positivo" e "Negativo"), a matriz é geralmente uma tabela 2×2 e é composta por quatro elementos principais:

1. **Verdadeiro Positivo (VP / True Positive - TP):** O modelo previu a classe positiva e o valor real era positivo. (Acerto)
2. **Verdadeiro Negativo (VN / True Negative - TN):** O modelo previu a classe negativa e o valor real era negativo. (Acerto)
3. **Falso Positivo (FP / False Positive - FP):** O modelo previu a classe positiva, mas o valor real era negativo. (Erro tipo I ou alarme falso)
4. **Falso Negativo (FN / False Negative - FN):** O modelo previu a classe negativa, mas o valor real era positivo. (Erro tipo II ou falha de detecção)



Documento Externo

<https://www.datageeks.com.br/matriz-de-confusao/>

Métricas Derivadas da Matriz de Confusão

A partir da matriz de confusão, podemos calcular várias métricas que oferecem insights profundos sobre o desempenho do modelo.

1. Acurácia

A **acurácia** representa a proporção de previsões corretas em relação ao total de previsões. Em outras palavras, é a fração de exemplos em que o modelo acertou.

É calculada da seguinte forma:

Acurácia=

+VN

FN+VN

Embora seja uma métrica bastante intuitiva, a acurácia pode ser enganadora em datasets desbalanceados. Imagine um dataset onde 95% das instâncias pertencem a uma classe negativa; um modelo que sempre prediz “negativo” terá alta acurácia, mas falhará em identificar os exemplos positivos.

2. Precisão (Precision)

A **precisão** indica quantas das previsões positivas feitas pelo modelo são realmente positivas. Esta é uma métrica importante quando o custo de um falso positivo é elevado, como em diagnóstico de doenças graves.

É calculada da seguinte forma:

Precisão=

VP

+FP

É relevante quando se deseja minimizar falsos positivos.

3. Recall (Sensibilidade)

O **recall**, ou **sensibilidade**, indica quantos dos exemplos positivos foram corretamente identificados pelo modelo. Essa métrica é essencial quando o custo de um falso negativo é alto, como em sistemas de segurança ou em diagnóstico médico. É calculado assim:

Recall=

VP

+FN

Ele é importante quando o objetivo é minimizar falsos negativos.

4. F1-Score

O **F1-Score** é a média harmônica entre precisão e recall. Ele é particularmente útil quando buscamos um equilíbrio entre esses dois aspectos:

$$F1 = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$$

Um F1-Score alto indica que o modelo é consistente tanto em identificar verdadeiros positivos quanto em evitar falsos positivos.

5. Especificidade

A **especificidade** mede a proporção de verdadeiros negativos identificados corretamente:

$$\text{Especificidade} = \frac{TN}{TN + FP}$$

Essa métrica é útil quando se deseja minimizar falsos positivos.

Como Interpretar a Matriz de Confusão?

Nos projetos que participei, a matriz de confusão é uma ferramenta muito útil para identificar erros específicos que um modelo está cometendo. Por exemplo, se o modelo tem muitos falsos negativos, isso pode indicar que ele está sendo excessivamente conservador, preferindo não classificar algo como positivo para evitar erros. Dependendo do contexto, isso pode ser problemático ou vantajoso.

Uma área que pode se beneficiar bastante dessa interpretação é a de

prevenção de fraudes bancárias. Caso um modelo tenha um grande número de falsos negativos, transações fraudulentas estão passando despercebidas. Já um número alto de falsos positivos pode gerar transtornos aos clientes, bloqueando transações legais.

Vantagens e Desvantagens da Matriz de Confusão

Uma das vantagens da matriz de confusão é sua simplicidade e clareza na visualização dos erros cometidos pelo modelo. No entanto, em problemas com muitas classes, a matriz pode se tornar extremamente grande e difícil de interpretar, o que leva à necessidade de sintetizar suas informações em métricas mais resumidas.

Também é importante mencionar que a matriz de confusão, por si só, não revela tudo sobre o modelo. Por exemplo, ela não considera a probabilidade atribuída a cada previsão. Assim, para uma análise mais detalhada, métricas como a **curva ROC** (Receiver Operating Characteristic) e a AUC (Area Under Curve) são comumente utilizadas.

Como Melhorar um Modelo de Classificação?

Ao analisar a matriz de confusão, algumas estratégias podem ser empregadas para melhorar a performance do seu modelo:

Rebalanceamento de Dados: Se o modelo apresenta muitos falsos negativos ou falsos positivos, pode ser um indicativo de que as classes estão desbalanceadas. Reamostrar o conjunto de dados ou usar técnicas como SMOTE ("Synthetic Minority Over-sampling Technique") pode ajudar.

Ajuste de Threshold: Dependendo do contexto do problema, alterar o limiar de decisão pode ser uma estratégia útil para equilibrar precisão e recall.

Escolha do Algoritmo: Alguns algoritmos são mais adequados

para diferentes contextos. Modelos baseados em árvores de decisão, por exemplo, são ótimos para explicar suas previsões, enquanto redes neurais têm tendência a ser mais precisas, mas menos interpretáveis.

O Vídeo 1 - dá continuidade no código de análise de fraudes usados anteriormente com KNN

- Importação de confusion_matrix e ConfusionMatrixDisplay
- a matrix de confusão será construída em cima dos dados y_test, y_predicto, ou seja os dados separados para teste e as previsões feitas pelo KNN
- O classification_report(y_test, y_predicto) retorna uma table com a os índices de cada métrica, precision, recall, f1-score, support
- F1-score, é uma média armônica entre precisão e acurácia

Resultado do exame: Métricas da Matriz da Confusão

(8) Positivo – doente

(11) Negativo – não tem doença

	SAUDÁVEL	DOENTE
DOENTE	VN 10 pessoas	FP 2 pessoas
SAUDÁVEL	FN 1	VP 6
	SAUDÁVEL	DOENTE

Acurácia	$6 + 10 / 10 + 2 + 1 + 6$	84,21%
Precisão	$6 / 6 + 2$	75%
Recall	$6 / 6 + 1$	85,71%
F1-SCORE	$2 \times ((0,75 * 0,8571) / (0,75 + 0,8571))$	

$$\text{Acurácia} = \frac{VP+VN}{VP+FP+FN+VN} \quad \text{Precisão} = \frac{VP}{VP+FP}$$

$$F1 = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}} \quad \text{Recall} = \frac{VP}{VP+FN}$$

Análise de escopo

O F1-score, testea tanto o resultado 0 “não é fraude” e 1 “fraude”

```
# Métricas de precisão, revocação, f1-score e acurácia
print(classification_report(y_test, y_predito))
```

```


```

	precision	recall	f1-score	support
0.0	0.99	0.98	0.98	182519
1.0	0.83	0.85	0.84	17481
accuracy			0.97	200000
macro avg	0.91	0.91	0.91	200000
weighted avg	0.97	0.97	0.97	200000

Para dados de saúde, precisão é melhor que acurácia.

ok Notebook 1

- Executado completamente