

FASE 1 - Visão Computacional - Aula 2 - Extração de Texto a partir de imagens ou PDFs (OCR)

<https://on.fiap.com.br/mod/conteudoshtml/view.php?id=520882&sesskey=2FxrQ9Zsmg>

Anotações

- Xxx

Hands On

- Utilização da biblioteca OpenCV;
- Carregamento, exibição e conversão para grayscale, redimensionamento, aplicação de filtros, detecção de bordas, desenho de formas em imagens;
- Outros tipos de processamento de imagens
 - filtragem e remoção de ruídos;
 - Thresholding e binarização;
 - Correção de inclinação (deskewing);
 - Segmentação
 - Tudo isso para reconhecer os caracteres de maneira precisa e eficiente
- Fluxo padrão
 - Aquisição de imagem (captura);
 - Processamento de imagem;
 - Todo o tipo de processamento para deixar os caracteres mais visíveis;
 - Conversão em escala de cinza
 - Quando mudamos para escala de cinza, realizamos uma redução do número de canais;
 - RGB (3 canais de informação de cor R, G, B)
 - Grayscale (1 canal de informação de cor 0-255)
 - Filtragem e remoção de ruídos
 - Thresholding e binarização
 - Conversão dos tons de cinza em uma imagem binária, onde cada pixel é apresentado como preto(0) ou branco(1)
 - 0 Representa o texto
 - 1 Representa o fundo
 - A binarização é realizada definindo um valor de limiar (threshold);
 - É o valor da intensidade de cinza de (0 a 255) que funciona como o ponto de corte ou fronteira para essa conversão;
 - Reconhecimento de texto
 - O reconhecimento óptico de caracteres (OCR), é o processo de converter o texto de uma imagem digital em texto editável e pesquisável;

- OCR analisa os padrões de pixels que correspondem aos caracteres específicos;
- **Utilizando algoritmos de correspondência de padrões, aprendizado de máquina e redes neurais, o OCR identifica e extrai os caracteres da imagem, transformando-os em dados textuais digitais** que podem ser manipulados, armazenado e pesquisados e todo tipo de manipulação com texto.

Ferramenta para brincar com as formação das cores em RGB

<https://rgbcolorpicker.com/>

GrayScale

https://www.w3schools.com/colors/colors_shades.asp

- Vídeo 01
 - Orientou sobre a instalação de bibliotecas e dependências
 - Explicou o código, linha por linha
- >>>Vídeo 02
 - Para extrair imagem de PDF
 - Nomalmene o processo consiste em:
 - Converter o PDF em imagem base 64;
 - Base 64 converte um dado binário para uma string de texto usando codificação Base64;
 - Essa codificação pode ser feita em imagens, PDFs, audio etc;
 - Base64 é uma sequência de caracteres texto ASCII imprimíveis, Ele usa um alfabeto de 64 caracteres;

```


X/4xRzBGy05ThYzYgC/z5HpJ0q1St6mrrsZGKIIszGQHA3d/1QlJzP/993X/xp7XQLbaS1/F8yF330Pgh+Y/f/r7N/j8/v1+KXy9+ofX3Y83It8T39PnjT
o+38PgdFvHL3zfI8w/vu7a1zuxfV3o6w0u/P4k3VvK/758Hyevx83r13yM6nx9Kb/Xnoc6vC62vD76hFh3LH8P6fNP/uz+8UFm1bdwoXhSSP792z4jS3+vwv
fm35gKrnwvZ5/MvW/f2NB/jC97+/e/7xAt1jkt5/cr6vvt7P4cY9nn5Zy/K1RvzwT98Isvr6cdt4s83Tj9GFH95Y8xwp+18fd2723nM7uRcYtavjLqLX
b4vgwfnCx5er9W+Fv5Mn6u72/nb/PDL0K+/fkTvyv0EInKdSGHUA44bzvKyyGm00JLe8xrpjey3V2ONKnzjX9xYU087NeK34nEp8XL8M2bw7ctv/Vz03H
kHPHoDfww8ym//ur9689/56+5dMqLg24+1YLxRec0WFnD9y6cISLhfc03wN9/v8LvF80fUpUI2lvmxgSh59LTav/yK304pz4nPH9U8LB1f1A2aIexuDCY
kI+BKShrJ8jbgGw0o2AjQvUw5TiIQz0JmkDengsXV2KLuze/U8D4bLZaoL8EmAmGppEsehoEK2cjf2pu5NCwZnM1lVrzrNkkouVkpR5Aaq5W1211L
Z7HS213KyVvLtrvY0ewEIdrZdee+u9jxHd4EaDaw0+P3hLxpLmjblRPNPscifvZetsqq62+xo47bWB1l113232P9wBKU4+dsqpp51+xiXbrr521233n
b7HT+19hXVP/39N6IWwGIXW6Toufojarzqav2+R8CcmGJGxGIORLwqA8R0VMx8CzLHRU4x8z1SFBVZPck2bgdfjBdmE6Ld8CN2/4jc34qbs/a34hb/VeScQv
d/ETLH6P4ct38St52eW91nyrUmvpE9fGEZVjy3v++U//z9eqBXNDy81AuHee2WyJ6fbj1U/0q6DQsR3mXcmEfi8Cv01aRKWEg/LFoqe0aW8uxos3mWlK
SfKZegs10RuamHK0jDDdrKKNC8iNm26LccifM6U8bo15A299yeoV7Azcm9a5I1te7fawGEBQBrrTc3nZPzKeU5Jda23a2n6NqzsNu065HnL645CZazr80
nj+tjgb81IyTgy4Lrcb/CTD9uHfG4298mR9ZjQxcmN32+HsW1UCyPqJv1h/PfFd/e7N/7+d2r0m7m4KuePvCQXuA+La2QkEF1bt+poFulrMbQmVq5Uxyn7
yNs+X0t1EwORP+QKT5nShrWxEMZSDP/Sj4t58KLRYyXLe484Qzifs0QLtRENa2YpR3HCT0RyoPC1e+dC9NvYGBFIQZ5QwVOVTHPRQj/4x0NsM7JMKLz5a3e
7NZ7vM630vUu/soVxb/fQLFvRYz2mrpLPD2JU0vH5fPjD2scmi33APyUVU4e1ur6j8IsRwZINSj9rLb2MvD2x3LDKZ6NL6tFdrcc+0U080wmXc3bF2M0/
ULDLUW5YAMBxveRajNg60UozBLHXDsOXzjUffskLRRmq611Lb9wM43LBKYPFLd1mNaaYecL3zczztQFD2iyzMLV/MJ8A5X0Tmc0IBIFpvrK6rvWL40yJm6
wMHqS1t8jx3s0usWbNsPIjItVIRKLm61+7wDIPgff4hx95+CoVvTPyUA1xXdmj0NBhjsfueFnem8le1RL1YPE601qIIGZ6MoQ8551bRCZxNv/412smf0s9
QYQFrWnIAS70SKoMLwGaxKBBkMzVLr4X9YUeATyzdCLNzZo9R9Bt0/KRL2cxLo0ZAE14au1IEY3Jywo8FxaRfzFr0JbFTJlMzn9auUojrLKWg0gJCQ16yBA
AAK6oMno4Icm/FVHJhSe1u14LxMPFwakHf3HXc30nhg0417QkhAXGhGFQh8jFK0558q1Qj3zBocyCBCJrqzJU1qFka2SFw00Lc/tuxvw2sUG7taRpiaZNEr
pyqbEID1LRGwEI3u11KA8kKUCbae4AsEf11lWZahjFkkGIj8DcT57Pr0IkmD6Sf/m+/O/UHStmbBE252zC7+LJPQJ1Sgfw/6NDPwX0jY4y3+Bey6McSq
ymDNscuINXLM15h++qc424GZj1FUVVPLapsv1GIGIjE1e6pChBqsd5gyd1rHaXJhn1a1TX4Yq4d85DSAHNTokssYCPjpmEav1dFOHZ/bNhtFSUW81o4LEb
nSR17IPxAc8jC0j+128EHBHlGZzyhM03rbuv1eGSeLSlyQySe5IBLZFa48JIMHjQI1s1H+eIwkyjFZ11+GZwk05TzJbCCRUk7DMN402Yx1GT600AY1M28hxt
A1Uf90SBmSewM0HcndbYzET5nQ1AMk0EwC3M1Y8Co4ARvT4Nje17IYw5p7oLk0jD1Kk0TSGv2Ra+5hIBPhacsXBgUQzPerQ0Zg0WbkJHhyR2saanzA0qz
eP1E23yY7nkHWNyISqyMuGFQ6yNEsfYI97k1qh2VFm6xjUhnGuDtd0YrklJbEjojeTddUUAUASOC53yY2dmN1JLRca1S6BYjg7RTRQZ1AP0x2R1Kf/ArY
9KZ0vAEUC08JGw44Nehk7MkyZcR8XgQLzxZnzVjbsnqN55MdpFHCZRU08uBayD1auXE81BER17CGVGt2w2tFrY/mYR0T5mg8MHRX27baE0KJXkDpgYCKej
RGqJgIOUjAERAKZsBKuJCOPT0POhdckAHfCqR7KMVT9ysBugDPeCZH+ClOyYD8dJLeFH81A3FFtUJhZ28dWYUs1eAV4a4duVr81YnLDFS0KPLBwIen+8r
QIKf1LtpPP31D6KA8E1yw/kv+Pm7++WF2r2q7p7MY1KOAMejRucqTtUwJXspg21h5cquEVB1qg1nAMKbNuxDSqbdSDcp0p251LRCZorFwkGMS04ubc0
223FpQbssvA2KX06/HUjdlMdlGLCanyoG2CdG6wFmJtdGG4Fk9lqSVBRTQk4EqCD1032WPp4w0ChkEGZDpmb15JYsR85iv1fsnQIQUtFHTa5G8PSy6C4ubC
Ln1pM3pgUJpVBJ/igX0aWezCF77NsYvtoC8G00C8Sns1s1rAtIsGvdNQ/gY0jYb1YB/LgQ080bcCgdb/1mzPUNCmj1kheNGz0xfgNkp1kFqb8HgcPC

```

- Depois extrair o OCR
- Mas com a ferramenta Paddle OCR:
 - Facilita, e dispensa o preparação de conversão prévia para Base64;

- Por ser gratuito é um pouco mais lento;
- Se precisar de mais performance, uma solução paga poderá ser considerada, como oferecida pela Microsoft Azure ou AWS;
- Utilizar o “en” english, é o que melhor se adequa para textos em português
- O código utiliza Expressões Regulares para conseguir captar dados específicos do texto capturado do PDF
 - CPF
 - # Expressão que aceita CPF com ou sem pontuação (o formato mais flexível)
 - `regex_cpf = r'\d{3}\.\d{3}\.\d{3}-?\d{2}'`
 - # OU, se você quiser apenas o formato com pontuação
 - `regex_cpf_pontuado = r'\d{3}\.\d{3}\.\d{3}-\d{2}'`
 - # OU, se você quiser apenas o formato com 11 dígitos
 - `regex_cpf_somente_numeros = r'\d{11}'`
 - CNPJ
 - RQCODE
 - Nesse caso a biblioteca de re (expressão regular) pode ser usado para um serach

Eu tentei de todas as formas colocar para funcionar o PaddleOCR, peguei código inteiro da IA, várias erros aconteceram durante o processo de instalação das bibliotecas via pip e via apt. Fui contornando todo tipo de incompatibilidade de versões, inclusive de compilação C, mas o resultado é que o código roda sem erro e nenhum texto foi capturado.

Os pdfs gerados não foram digitalizados por fato, isso pode ser uma hipótese.

Vou bater uma foto de um texto e converter para PDF para ver o que acontece

- eu bati uma foto de uma receita média em português;
- eu converti para imagem e não deu certo
- não deu erro e não consegui capturar nada

Decisão é criar um Google Colab e rodar o código passo a passo informada na aula a partir das instruções do Paddle OCR

- Criei um colab com todos os comandos do exercício;
- Resolvi todos os problemas de compatibilidade de versões
- Rodei e não conseguiu pegar nenhum texto
- Depois exportei o código Colab e o código Python

- O código Python eu adaptei para rodar com arquivo local
- Rodei tanto o Colab quanto o novo código Python adaptado, diretamente na minha IDE Visual Studio, mas infelizmente o resultado foi o mesmo, NENHUM ERRO MAS NENHUM TEXTO CAPTURADO DO PDF.

Continuando a leitura do saiba mais