



FASE 1 - Visão Computacional - Aula 4 - Redes Neurais Convolucionais (CNN)

<https://on.fiap.com.br/mod/conteudoshtml/view.php?id=520884&sesskey=ThitbmUQSK>



Anotações


- Arquiteturas CNNs
 - LeNet-5
 - AlexNet
 - VGG
 - ResNet
 - EfficientNet
- Técnicas
 - Transfer Learning
 - Utilização de redes pré-treinadas para resolver problemas específicos;
 - Ajuste de modelo pré-treinados para resolver problemas específicos;
 - Segmentação de imagens
 - U-Net
 - Mask R-CNN
- >>> Video 01



Nome	Neurônio Humano	Neurônio Computacional
Entrada de informação (input)	Núcleo • Vontade de flexionar um braço ou uma perna • Sinal elétrico produzido pelo cérebro é enviado para os dendritos e encaminhado e processado pelo núcleo	Corpo do Neurônio • Input de uma imagem • Dependendo do tipo de dados poderão se aplicados pesos que representam a importância daquela entrada no resultado final e são ajustados durante o processo de aprendizado
	Corpo • O estímulo elétrico é processado pelo corpo do neurônio humano;	Corpo neurônio computacional • informação digital é que recebida e processada pelo corpo do neurônio;
	Axônio • Executa a ação de mover o membro desejado	Função de Ativação • Aprende sobre as relações e padrões • Linear ○ Regressão Linear simples; • Não Linear ○ ReLU ■ (Rectified Linear Unit) ○ Sigmoid ■ (Logística) ○ Tanh ■ (Tangente Hiperbólica)

		○ Softmax ■ Geralmente usada no final porque favorece a classificação vai acontecer no Perceptor
	Fibra terminal do Axônio • Gera uma saída que é uma Sinapse	Saída • Resultado da saída de todo processamento;
Comunicação com outros neurônios	Sinapse • Nesse caso a sa	Perceptor • Esse resultado então é aplicado para o propósito da necessidade do caso de uso em que foi aplicado. • Por exemplo o perceptor pode atuar como um classificador binário (decisor) em problemas de reconhecimento de padrões, separando dados em duas classes

Na rede neural artificial (imagem da direita) os neurônios artificiais se conectam entre si com o objetivo de executar uma função.



As Redes Neurais Convolucionais são projetadas para processar **dados estruturados** em forma de grade, como imagens.

Labelimg

Ferramenta utilizada para rotular imagens usado em projetos de Visão Computacional. Ela permite que um usuário desenhe caixas delimitadoras (bounding boxes) ao redor de objetos de imagens e atribua um rótulo (classes) a cada caixa.

Nesta aula o professor Rodrigo deu uma dica para rodar os modelos em colab porque lá o processamento (que é muito pesado e custoso) utiliza-se de GPUs gratuitas

Orientações

- Em Notebook settings
- Por default um notebook do colab vem marcado para CPU mas pode ser atualizado para T4 - GPU
- Se tiver plano pago no Colab outras GPUs poderão ser utilizadas como
 - A100 GPU
 - L4 GPU
 - TPU V2

Bibliotecas que serão utilizadas

- Tensorflow
- Keras
- Tensorflow-datasets

As Redes Neurais Convolucionais

- Estrutura da Convolução
 - Operação de extração de características importantes da entrada; (exemplos)
 - Verifica a existência de bordas;
 - Verifica a existência de texturas;
 - Verifica a existência de filtros;
 - Verifica a existência de tem contornos internos diferentes do externo;
 - Verifica coloração;
 - Verifica de forma geral toda a estrutura por trás da imagem;
- Max Polling
 - É um processo de redução de dimensionalidade (Downsampling) em matrizes
 - Por exemplo uma matriz 4x4 vira uma matriz 2x2
 - São mantidas as características mais relevantes
 -

Vídeo 02

- Será treinada um dataset de manuscritos de um Dataset do MNIST;
- As redes neurais trabalham com múltiplas camadas de processamentos e filtros
- Em Redes Neurais os modelos precisam ser compilados
 - Exemplo
 - `model.compile(optimizer='adam')`
 - 'adam' é o primeiro modelo criado e a orientação é iniciar os testes por ele;
 - 'adam' é um modelo popular e mais simples;
 - Recomendado sempre pelo mais simples
- LR é a taxa de aprendizado de um algoritmo de aprendizado

Continuar na leitura do texto depois do vídeo 2

Estrutura Básica de uma CNN

- Composta de várias camadas
 - Cada camada desempenha um papel crucial no processo de aprendizado e extração de características;
 - Estrutura básica
 - Camadas convolucionais;
 - Camada de polling;
 - Camadas totalmente conectadas;

- Camadas convolucionais
 - Extrai características importantes das imagens de entrada;
 - Um filtro convolucional é uma pequena matriz de pesos que desliza sobre a entrada (imagem), realizando a convolução. O processo pode ser descrito matematicamente;
 - Compartilhamento de pesos
 - Um mesmo conjunto de filtros é aplicado em toda a entrada, reduzindo a complexidade computacional;
 - Receptive field
 - Cada neurônio em um mapa de características convolucional é conectado a uma pequena região da entrada, conhecida como campo receptivo, o que permite a detecção de padrões locais.
 - Camada de Pooling
 - As camadas de pooling são intercaladas entre as camadas convolucionais e têm a função de reduzir a dimensionalidade dos mapas de características, preservando as características mais importantes;
 - Tipos de Pooling
 - Max pooling
 - seleciona o valor máximo em cada região da matriz de entrada;
 - Average pooling
 - calcula a média dos valores em cada região da matriz de entrada
 - Camadas conectadas (camadas densas)
 - As camadas totalmente conectadas, também conhecidas como camadas densas, estão localizadas no final da rede e são responsáveis por realizar a classificação com base nas características extraídas pela camada convolucional e de pooling;
 - Camadas Fully Connected
 - As camadas totalmente conectadas (fully connected) são semelhantes às camadas nas redes neurais tradicionais, onde cada neurônio é conectado a todos os neurônios da camada anterior

- Arquiteturas pioneiras
 - Modelo LENET-5
 - 1998, Reconhecimento de caracteres manuscritos;
 - Modelo AlexNET
 - 2012, Introduziu o uso de GPUs para treinamento em larga escala e empregou funções de ativação não lineares como ReLU, assim como técnicas de regularização com dropout;

- Arquiteturas Avançadas
 - VGG
 - 2014, adotou uma abordagem de profundidade crescente e convoluções 3x3;

- Destacou a importancia da profundidade na extração de características;
- ResNeT
 - 2015, Cionveito das conexões residuais, permitindo o tyreinamento de redes mais profunda e mitigando problemas de derretimento de gradientes;
- EfficientNet
 - 2019, adotou uma abordagem de escalonamento composto, otimizando simultaneamente largura, profundidade e resolução da rede.
 - Modelos altamente eficientes, com desempenho superior em relação à complexidade do modelo.
 - Indicada para apicações em dispositivos com recuros limitados;