

FASE 1 - Visão Computacional - Aula 5 - Redes Neurais Pré-Treinadas (Yolo)

<https://on.fiap.com.br/mod/conteudoshtml/view.php?id=520885&sesskey=N6dKrDeKHB>

Leitura da parte textual

Anotações

- Transfer Learning
 - O modelo treinado em uma tarefa (a tarefa fonte) é reutilizado como ponto de partida para um modelo em uma segunda tarefa (tarefa alvo) evitando ter que treinar um modelo do zero fazendo o aproveitamento do conhecimento previamente adquirido.
 - Etapas
 - Treinamento Inicial
 - Transferência de Conhecimento
 - Ajuste Fino (fine-tuning)
 - Benefícios
 - Economia de tempo e de recursos;
 - Melhoria de desempenho;
 - Generalização Melhorada;
 - Rápida Adaptação a Novas Tarefas;
 - Redução da Necessidade de Grandes Conjuntos de Dados;
 - Exemplos de aplicação
 - Visão Computacional
 - Classificação de imagens;
 - Detecção de objetos;
 - Processamento de Linguagem Natural (NLP)
 - Análise de sentimentos;
 - Tradução de idiomas;
 - Reconhecimento de Voz
 - Transcrição Automática;
 - Medicina e Saúde
 - Diagnóstico por imagem
 - Predição de Doenças
- Redes Neurais Pré-treinadas
 - São modelos de Deep Learning (aprendizagem profunda), que foram treinados em grande conjunto de dados para resolver tarefas específicas,

como classificação de imagens, detecção de objetos ou tradução de linguagem natural.

- O treinamento prévio dessas redes é realizado utilizando vastos recursos computacionais e grandes volumes de dados, permitindo que elas aprendam representações úteis e características complexas dos dados. Uma vez treinadas, essas redes podem ser reutilizadas em novas tarefas, muitas vezes com apenas pequenos ajustes (um processo conhecido como fine-tuning).
- As redes neurais pré-treinadas oferecem uma base sólida para desenvolver soluções de inteligência artificial eficientes de alta qualidade, economizando tempo, recurso e acelerando o progresso na área;
- Modelos pré-treinados
 - CNNs (Convolutional Neural Networks)
 - Modelos
 - ResNet
 - VGG (Visual Geometry Group)
 - Inception (GoogLeNet)
 - RNNs (Residual Networks)
 - Modelos
 - ResNet-18
 - Mais básico
 - ResNet-50
 - Intermediário
 - ResNet-101 e ResNet-152
 - Alta precisão
 - Detecção de Objetos
 - YOLO (you Only Look Once)
 - Modelos
 - YOLO V1
 - YOLO V5
 - YOLO V8
 - Ferramentas de Benchmarks
 - ImageNet
 - Avalia precisão de modelos de classificação de imagens;
 - COCO (Common Objects in Context)
 - Avalia a precisão em detecção de objetos, segmentação e keypoint detection.
 - PASCAL VOC
 - Avalia precisão de detecção de objetos e segmentação. É utilizado para comparar a eficácia de diferentes modelos e técnicas em identificar objetos em imagens variadas;
 - CIFAR-10 e CIFAR-100
 - Conjunto de datasets menores utilizadas para benchmarks de classificação de imagens em categorias simples. São úteis para avaliar a capacidade de generalização e eficiência de modelos menores e mais rápidos.

ok assistir Vídeo 01

- YOLO precisa de GPU para Rodar

No vídeo o professor não foi preciso ao tentar explicar o conceito de dados de TESTE, VALIDAÇÃO e TREINO. Durante a configuração do arquivo coco128.yaml ele disse:

- Teste é opcional
- Validação significa que é teste e teste significa que é validação
- Tem que se atentar que é o ao contrário
- Não sei como eles determinaram isso, talvez seja um padrão de convenção americana, eu não sei dizer
- Ou seja ele demonstrou que desconhece a diferença entre VALIDAÇÃO e TESTE e reafirma que SÃO A MESMA COISA, o que obviamente está equivocado.

Entendendo o conceito correto sobre a diferença entre os grupos de dados de TREINAMENTO, VALIDAÇÃO e TESTE

Essa é uma pergunta fundamental no desenvolvimento de modelos de *Machine Learning* e, em particular, em Redes Neurais Convolucionais (CNNs).

Para garantir que o modelo não apenas aprenda os dados que viu (treinamento), mas também seja capaz de fazer previsões precisas em dados novos e não vistos (generalização), o conjunto de dados original é tipicamente dividido em três subconjuntos: **Treinamento, Validação e Teste**.

Abaixo estão as definições de cada conceito no contexto de uma rede neural (como uma CNN):

1. Conjunto de Treinamento (Training Set)

- **Definição:** É a maior parte do conjunto de dados, usada para **ensinar** o modelo.
- **Função:** O modelo (a CNN) utiliza esses dados para **ajustar seus parâmetros internos** (como os pesos dos filtros convolucionais e *biases* nas camadas) por meio do algoritmo de otimização (ex: *backpropagation*).
- **O que acontece:** O modelo calcula o erro entre suas previsões e os rótulos verdadeiros e, em seguida, ajusta seus pesos para minimizar esse erro.
- **Uso em CNN:** As CNNs aprendem a extrair características automaticamente (bordas, texturas, formas, etc.) a partir das imagens neste conjunto, formando os pesos dos seus filtros convolucionais.

2. Conjunto de Validação (Validation Set)

- **Definição:** É um subconjunto de dados **separado** do conjunto de treinamento e teste. **Não** é usado para ajustar diretamente os parâmetros do modelo.
- **Função:** É usado para **monitorar** o desempenho do modelo durante o treinamento e para **ajustar os hiperparâmetros** (configurações do modelo que não são

aprendidas diretamente, como taxa de aprendizado, número de épocas, tamanho do *batch* ou a arquitetura da CNN).

- **O que acontece:** A performance neste conjunto ajuda a identificar o problema de **Overfitting** (sobreajuste), que ocorre quando o modelo aprende o ruído e os detalhes irrelevantes dos dados de treinamento, performando mal em dados não vistos. Se o erro no conjunto de treinamento continua diminuindo, mas o erro no conjunto de validação começa a aumentar, o treinamento deve ser interrompido (técnica de **Early Stopping**).
- **Uso em CNN:** Avaliar a capacidade de generalização do modelo em cada época de treinamento para otimizar os hiperparâmetros antes do teste final.

3. Conjunto de Teste (Test Set)

- **Definição:** É um subconjunto de dados **completamente inédito** e separado, que não foi usado em momento algum durante o treinamento ou o ajuste de hiperparâmetros (validação).
- **Função:** É usado para fornecer uma **avaliação final e imparcial** da capacidade de generalização do modelo.
- **O que acontece:** A performance neste conjunto simula como o modelo se comportará na **prática**, com dados do "mundo real" que nunca viu. O erro ou a acurácia no conjunto de teste é o valor que você deve reportar como o desempenho final do seu modelo.
- **Uso em CNN:** Medir a acurácia, precisão, *recall* ou outra métrica para a tarefa (ex: classificação de imagens) com o modelo **final e pronto**.

Característica	Conjunto de Treinamento	Conjunto de Validação	Conjunto de Teste
Objetivo Principal	Ajustar os pesos (parâmetros) do modelo.	Ajustar os hiperparâmetros e evitar o <i>overfitting</i> .	Avaliar o desempenho final e real do modelo.
Uso no Modelo	Direto (o modelo "aprende").	Indireto (para monitoramento/otimização).	Nenhum (apenas avaliação final).

Exemplo de Tamanho	$\approx 60\%$ a 80% do total.	$\approx 10\%$ a 20% do total.	$\approx 10\%$ a 20% do total.
---------------------------	-----------------------------------	-----------------------------------	-----------------------------------

Gostaria de saber mais sobre a técnica de **validação cruzada** (Cross-Validation), que é uma alternativa para o uso do conjunto de validação?

Depois do vídeo também li o texto complementar de fechamento da aula

- Outros modelos de detecção além do YOLO
 - SSD (Single Shot MultiBox Detector);
 - Faster R-CNN
- Desafios e dificuldades do YOLO
 - ainda tem dificuldades de detecção de objetos pequenos ou muito próximos uns dos outros;
 - Buscam ainda melhorar o balanceamento entre a complexidade do modelo e a capacidade de execução em dispositivos de baixa potência;
- Por onde evoluir e aprender mais
 - A comunidade do YOLO é bem ativa, lá é possível encontrar muitos materiais como documentação e tutoriais;