

FASE 1 - Visão Computacional - Aula 6 - Redes Neurais Adversativa (GAN)

<https://on.fiap.com.br/mod/conteudoshtml/view.php?id=520886&sesskey=UCNKT78pgS>

Anotações

- Arquitetura GANs
 - DCGAN
 - Uso de redes Convolucional
 - CGAN
 - Usa audios
 - StyleGAN
 - Controle sobre o stilo da imagem,
 - BigGAN
 - Gera imagem de alta definição
- GAN's funcionam com duas Redes
 - Uma Geradora
 - Gera imagens sintéticas
 - Outra Discriminadora
 - Tenta indentificar o que não é autentico, verdadeiro,
- Aplicações
 - Geração de imagens realistas;
 - Design Gráfico,
 - Cinema,
 - Jogos,
 - Realidade Virtual e aumentada
 - Transferencia de estilo
 - Transferir o estilo de uma imagem para outra;
 - Criação de obras de arte digitais únicas, exclusivas e impressionantes no que se diz respeito ao realismo;
 - Data augmentation para treinamento de modelos
 - AS GANs são eficarez no aumento de dados, (geração de dados sintéticos adicionais)
 - Frameworks
 - TensorFlow pode ser utilizado para a implementação de uam GAN Simples

Assistir o vídeo 01

https://github.com/engenheirorodrigoviannini/gan-generative-neural-network/blob/main/GENERATIVE_AI_MINST_20231205d.ipynb

Desafio

Nesta aula foi colocado um desafio

Tem um desafio interessante de detecção de Rostos em Tempo Real

Depois que eu terminar a entrega do trabalho e se o código complementar da aula funcionar tentarei fazer esse desafio.

Exemplos de hiperparâmetros na configuração das Redes GAN

- EPOCHS
- BATCH_SIZE
- noise_dim
- num_examples_to_generate
- seed

Anatomia das Redes GAN (´pesquisado na IA)

Rede Geradora

- Entrada:
 - Vetor de ruídos aleatório que é transformado em uma imagem sintética;
- Primeira camada (Densa) - Totalmente Conectada
 - Expande o ruído, criando um vetor de características de dimensão maior;
 - `noise = tf.random.normal([aBATCH_SIZE, noise_dim])`
- Camadas ocultas
 - Camadas convolucionais transposas (Deconvolução)
 - São camadas principais de “expansão”.
 - São aplicadas convoluções que aumentam progressivamente o tamanho da matriz;
 - Pode ocorrer normalização em batch;
 - Pode ocorrer uma ativação LeakyRel (Leaky ReLU) para garantir um treinamento estável;
 - Leaky ReLU, que significa **Unidade Linear Retificada Vazante** (*Leaky Rectified Linear Unit*), é uma variação da função de ativação ReLU padrão.

- Ele evita o “Dying ReLU” (Neurônio Morto), quando o ReLU (padrão) quando recebe entrada negativa, ele sempre produz zero na saída. Porém com o LeakyRel, o retorno seria um pequeno gradiente (alfa)
 - Transformação de saída 1D em um tensor 3D usando a função `layers.Reshape`
 - No exemplo mostrado pelo professor, o código foi repedido para criar pelo menos duas camadas ocultas;
- Camada de saída
 - Camada Convolutiva Final (Tanh)
 - Geração da imagem de saída na resolução e número de canais desejados;
 - A ativação “Tanh” é comum para mapear os pixels para o intervalo $[-1,1]$;

Rede Discriminadora

- Entrada:
 - Imagem
 - Recebe uma imagem, que pode ser real (do dataset de treinamento) ou falsa, gerada (produzida pela Rede Geradora)
- Camadas ocultas
 - Camadas convolucionais
 - São camadas principais de “redução”.
 - São extraídas características (feições) da imagem e reduzem progressivamente suas dimensões, preparando-as para a classificação;
 - Pode ocorrer uma ativação LeakyRel (Leaky ReLU) para garantir um treinamento estável;
 - Leaky ReLU, que significa Unidade Linear Retificada Vazante (Leaky Rectified Linear Unit), é uma variação da função de ativação ReLU padrão.
 - Ele evita o “Dying ReLU” (Neurônio Morto), quando o ReLU (padrão) quando recebe entrada negativa, ele sempre produz zero na saída. Porém com o LeakyRel, o retorno seria um pequeno gradiente (alfa)
 - Aplica layer.Dropout para evitar “overfitting”
 - Achata a saída da camada usando layers.Flatten
- Camada Densa - Totalmente Conectada
 - Pega o vetor de características extraído e o processa para a decisão final;
- Camada de saída - Camada Densa Final (com Sigmoid)
 - Definição da função de perda e otimização
 - Usando Tensor Flow e Keras
 - `cross_entropy = tf.keras.losses.BinaryCrossentropy(from_logits=True)`
 - **O otimizador ADAM (Adaptive Moment Estimation) é aplicado.**
 - Ele treina a Rede Discriminadora incluindo pesos de sua camada de saída, com o objetivo de maximizar a precisão na distinção entre amostras reais e geradas;
 - A função principal da função de ativação **Sigmoide** (ou logística) é transformar a saída final em uma **probabilidade**;
 - Emite um único valor (escalar), geralmente entre 0 e 1, que representa a probabilidade de a imagem de entrada ser REAL;
- Saída
 - Probabilidade;
 - Valor final
 - Perto de 1, significa que a Rede Discriminadora acredita que a imagem é REAL;
 - Perto de 0, significa que a Rede Discriminadora acredita que a imagem tem maior probabilidade de ser FALSA;

A arquitetura de Redes Adversárias Generativas (GANs) é uma área de pesquisa muito ativa e em **constante evolução**, então o "modelo mais recente" pode mudar rapidamente.

No entanto, um dos desenvolvimentos mais notáveis e influentes nos últimos anos, especialmente para a geração de imagens de alta qualidade, tem sido a família de modelos **StyleGAN**, desenvolvida pela NVIDIA:

- **StyleGAN:** Introduziu a capacidade de controlar atributos visuais específicos nas imagens geradas (como a cor do cabelo ou a pose do rosto) ao injetar o vetor latente em múltiplas camadas através de um mapeamento e um bloco de adaptadores de estilo (AdaIN).
- **StyleGAN2:** Melhorou o StyleGAN, removendo artefatos de gota d'água e aumentando a fidelidade da imagem com uma arquitetura mais refinada e normalização aprimorada.
- **StyleGAN3:** Focou em resolver o problema do "entrelaçamento" de texturas, tornando as representações da rede mais robustas a transformações, como rotação ou translação, resultando em maior coerência espacial e temporal em vídeos.

Embora o StyleGAN seja amplamente reconhecido pela qualidade de imagem, outras arquiteturas GAN notáveis e mais recentes que abordam problemas diferentes incluem:

- **GANs baseadas em Difusão:** Embora não sejam GANs no sentido estrito (com um gerador e um discriminador adversarial), os modelos de difusão se tornaram a **referência atual** para a geração de imagens de altíssima qualidade (como DALL-E 2, Stable Diffusion e Midjourney), superando o desempenho de muitas arquiteturas GAN tradicionais.
- **Modelos de Múltiplas Tarefas:** Arquiteturas que integram GANs com outros métodos ou são adaptadas para tarefas específicas, como *CycleGAN* (para tradução de imagem de um domínio para outro, sem pares de dados) ou *SRGAN* (para super-resolução).

Conclusão:

- Para **GANs puras** em geração de imagens, o **StyleGAN3** (e suas variantes) é uma das arquiteturas mais avançadas e robustas.
- Para **Geração de Imagens de estado-da-arte** em geral (embora não sejam tecnicamente apenas GANs), os **Modelos de Difusão** são atualmente o padrão.

Gostaria de saber mais sobre a arquitetura do **StyleGAN3** ou sobre os **Modelos de Difusão**?

Repositório dos códigos das aulas

https://github.com/FIAP/IADEVS_COMPUTERVISION

- ok fazer o clone do repositório
- ok instalar as dependencias do projeto hand-tracking-libras
- ok Instalar as dependencias do projeto simple-squat-analysis
- ok desempactar o .zip “Mask_waring...”
- yolov5_face_mask_detectio

CONTINUAR

ASSISTIR OS VÍDEOS NOVAMENTE E TENTAR RODAR OS VÍDEOS

VOU FAZER ISSO ASSIM QUE FINALIZAR A ENTREGA DO TRABALHO TECH
CHALLENGER 1